产品设计文档：本地知识助手（从 RAG 到 Agentic RAG 的演进实践）

- 1. 项目概述（TL;DR）
- 2. 问题定义 & 用户需求
- 3. V1：基础 RAG 系统设计
- 4. V2：Agentic RAG 系统设计（决策驱动升级）
- 5. V1 vs V2 对比
- 6. 关键设计思考
- 7. 效果评估
- 8. 未来扩展
- 9. 我的角色（AI PM）

1. 项目概述（TL;DR）

1.1 一句话总结

本项目是一个面向个人知识管理场景的本地知识助手，从 V1 的基础 RAG 检索问答，演进到 V2 的 Agentic RAG，通过 Router、Tool、Memory 和 Agent Core，让系统从“被动检索回答”升级为“能判断、能调用工具、能保留上下文的知识助手”。

不仅完成了从 RAG 到 Agent 的演进，也验证了这套方案在个人知识管理、项目复盘和资料整理场景中的实际使用价值。

当前项目定位仍是个人知识工作台 MVP，不包装成已商业化产品；但在产品设计上保留了向小团队私有知识助手延展的路径思考。

1.2 三点总结（问题 / V1 / V2）

维度	内容
问题	个人笔记、项目资料和工作沉淀分散在 Obsidian 与本地文件中，关键词搜索难以找回语义相近内容，直接问 LLM 又缺少来源依据和隐私保障。
V1	建立本地知识助手：文档导入、chunk 切分、本地 embedding、Chroma 向量检索、基于上下文回答、来源引用和 Web GUI。
V2	在 RAG 之上加入 Agent 控制层：Router 判断是否检索，RAG 被封装为 search_docs Tool，Memory 保存最近上下文，Agent Core 负责任务调度和结果生成。

> **项目定位**
> 这不是两个割裂的 demo，而是同一个知识助手产品的两阶段演进：先解决“资料找得回、答案有依据”，再解决“系统会判断、会调用工具、能支持连续任务”。

2. 问题定义 & 用户需求

2.1 用户场景

核心用户是有大量本地知识资产的个人知识工作者，典型场景包括：

场景	真实问题	用户期望
项目展示	准备项目展示或阶段复盘时，需要从大量项目文档、分析记录和验证结果中找回可引用材料。	输入一个问题后，系统能找回相关项目资料，并给出有来源的回答。
项目复盘	一个项目的背景、需求、方案、验证结果分散在多个 Markdown 和本地文档里。	能跨文件召回相关片段，快速拼出项目全貌。
知识检索	用户记得“大概写过某个观点”，但不记得关键词、文件名或目录位置。	用自然语言搜索，而不是依赖精确关键词。
隐私资料管理	私人笔记、项目复盘和本地资料不适合上传到云端知识库。	embedding、向量库、缓存和回答过程尽量留在本地。
连续追问	用户不是只问一次，而是会基于上一轮结果继续追问、对比或总结。	系统需要理解最近上下文，而不是每次都当作孤立问题处理。

2.2 核心问题

一句话抽象：

用户真正需要的不是一个“会聊天的模型”，而是一个能在本地资料中找回依据、判断是否需要检索、并支持连续追问的可信知识助手。

这个问题可以拆成三层：

层级	具体表现	产品挑战
找得到	文件多、目录多、关键词不确定。	需要语义检索，而不是只靠文件名和关键词。
信得过	LLM 可以生成流畅答案，但可能没有依据。	回答必须绑定来源片段，方便用户复核。
用得顺	用户会连续追问，也会提出不同类型任务。	系统需要具备路由、上下文和工具调用能力。

2.3 产品目标

目标	说明
本地可控	资料、embedding、向量库、缓存和日志尽量保留在本机。
来源可信	回答必须绑定来源片段，方便用户回到原文复核。
日常可用	提供 Web GUI，降低命令行门槛。
可持续演进	V1 先完成基础 RAG，V2 再加入 Agent 控制层。
可产品化延展	当前先服务个人场景，后续可探索小团队本地知识助手，但不在本阶段追求完整商业化。

2.4 技术选型（为什么选择 RAG）

为什么不是 fine-tune：

维度	Fine-tune 的问题	RAG 的优势
知识更新	私人笔记和项目资料经常变化，微调成本高。	新增文档后重新索引即可更新知识。
来源追溯	微调后的模型很难说明答案来自哪个文件。	RAG 可以展示来源文件、标题和片段。
隐私控制	微调通常需要上传训练数据或维护更复杂训练环境。	本地知识助手 可以把资料、embedding 和向量库留在本机。
项目阶段	当前目标是作品集 Demo 和个人使用工具，不需要训练新模型。	RAG 更适合快速验证产品闭环。

为什么不是纯 LLM：

维度	纯 LLM 的问题	RAG 的解决方式
私有知识	模型不知道用户本地资料。	通过检索把相关资料提供给模型。
幻觉风险	模型可能编造不存在的项目细节。	回答要求基于召回片段，并附引用。
可复核性	用户难以判断答案是否真实。	用户可以回到原文检查依据。
长期维护	资料变化后模型本身不会自动更新。	重建或增量更新索引即可。

产品决策：

先用 RAG 建立“可信知识检索层”，再在 RAG 之上加入 Agent 控制层。这样既保留来源可追溯，又能逐步增强系统的决策和任务执行能力。

3. V1：基础 RAG 系统设计

3.1 架构设计

V1 的系统目标是跑通一个本地知识库 RAG 闭环：

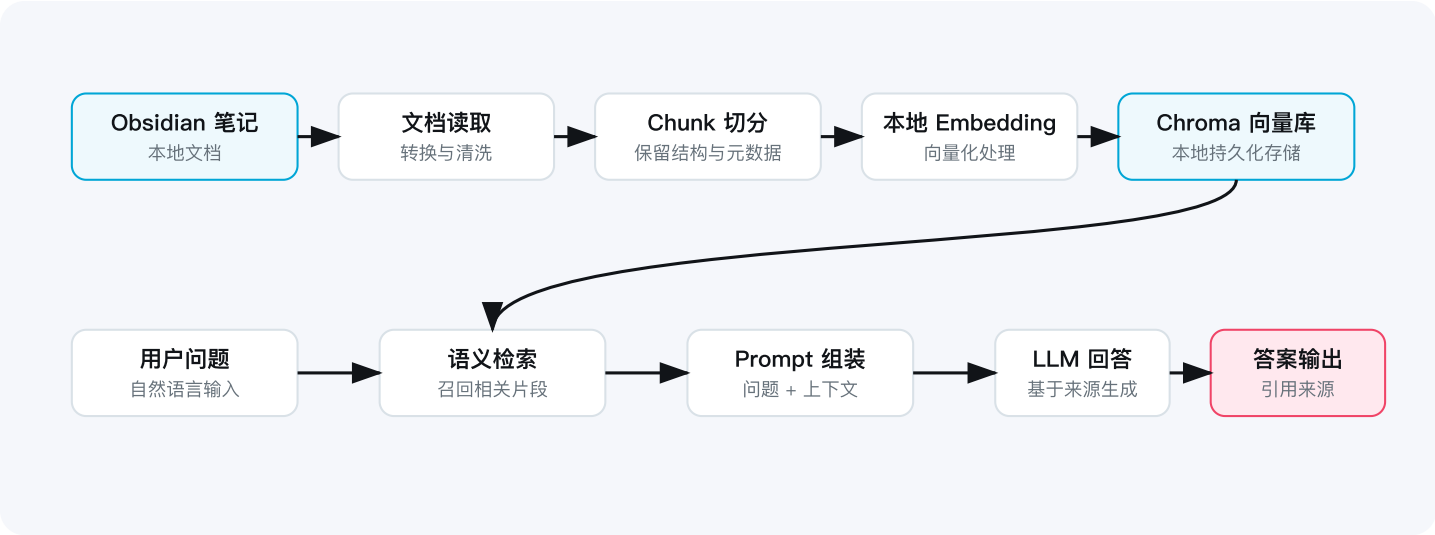

V1 基础 RAG 架构流程图

架构分层：

层级	作用	设计重点
数据源层	Obsidian Markdown、本地文档、脱敏测试文档。	原始文件只读，不直接修改。
文档处理层	文档转换、清洗、切分。	保留标题、路径、来源类型等元数据。
向量层	本地 embedding + Chroma。	语义召回、本地持久化、可迁移。
检索层	query embedding + 相似度搜索。	返回相关片段，而不是直接给结论。
生成层	将召回片段放入 prompt，让 LLM 生成回答。	要求基于上下文，不编造。
体验层	FastAPI + Web GUI。	降低命令行门槛，让项目像产品而不是脚本。

3.2 核心流程（Retrieve → Generate）

V1 的核心链路是“先检索，再回答”：

1. 用户在 GUI 中输入自然语言问题。
2. 系统将问题转成 query embedding。
3. Chroma 根据向量相似度召回相关 chunks。
4. GUI 展示候选片段、来源文件、标题和片段内容。
5. 如果用户需要问答，系统把召回片段组装进 prompt。
6. LLM 基于上下文生成回答。
7. 回答区展示结果和引用来源。
8. 用户根据来源回到原文复核。

这个流程的产品原则是：

> 先让用户看到依据，再让模型组织答案。

3.3 关键模块设计

3.3.1 文档处理

chunk 切分不是简单按字数硬切，而是要兼顾“可检索”和“可理解”：

设计点	说明
保留结构	尽量保留标题、章节和文件路径，便于回到原文。
合并短章节	对标题很多但正文很短的文档，合并短章节，避免碎片过多。
控制 chunk 大小	chunk 太小会丢失上下文，太大又会影响召回准确性和 prompt 成本。
保留元数据	每个 chunk 记录 source_type、path、title、heading、chunk_id。

3.3.2 向量检索

V1 采用轻量语义检索策略：

策略	说明
本地向量库	使用 Chroma 持久化保存 embedding 和元数据。
top_k 召回	根据用户问题召回若干个最相关片段。
来源筛选	GUI 支持按资料源筛选，例如 Obsidian 或本地文档。
路径刷新	文件重新索引时，先清理同一路径旧 chunks，再写入新 chunks。

3.3.3 Prompt设计

V1 的 prompt 重点不是“让模型发挥”，而是限制模型只基于来源回答：

Prompt 原则	产品目的
优先使用上下文	降低脱离资料自由发挥。
上下文不足时说明不确定	避免伪造项目细节。
回答简洁清晰	符合知识检索场景，不做过度创作。
输出引用来源	让用户能复核答案。

3.4 系统能力

V1 已经验证的效果：

指标	当前结果
已索引文件	163 个文件
向量片段	390 个 chunks
运行方式	本地运行，Ollama embedding + Chroma + FastAPI GUI
典型命中	文件管理规则、RAG 使用手册、项目资料和产品说明等问题可以召回对应来源

用户体验变化：

- 从“翻目录找文件”变为“自然语言找资料”。
- 从“直接问模型但不知道依据”变为“先看来源，再看回答”。
- 从“命令行工具”变为“可日常打开的 Web GUI”。

3.5 存在问题（必须为V2铺垫）

V1 虽然完成了 RAG 闭环，但它仍然是一个相对静态的系统。

V1 问题	表现	产品洞察
所有问题强制检索	无论用户问的是闲聊、解释概念、还是需要查资料的问题，系统都默认走检索。	RAG 缺少“是否需要检索”的判断能力，导致流程不够智能。
无决策能力	系统只能被动接收问题并召回片段，不能判断任务类型。	用户真实需求往往是“整理项目”“生成报告”“对比资料”，不是单一问答。
无多轮记忆	每轮问题相对独立，无法自然继承上一轮上下文。	知识助手需要支持连续追问，否则用户每次都要重复背景。
工具边界不清	检索只是代码流程的一部分，没有被抽象成可被调用的工具。	如果后续要扩展为多工具系统，必须先把 RAG 能力工具化。
过程不可解释	用户看到结果，但不一定知道系统做了哪些步骤。	面向 Agent 的产品需要展示决策、工具调用和来源，降低黑盒感。

V1 的核心结论：

> 基础 RAG 解决了“知识可检索、回答可追溯”，但还没有解决“系统会不会判断、会不会调用工具、能不能连续完成任务”。

4. V2：Agentic RAG 系统设计（决策驱动升级）

Agentic RAG 的核心思想：

不再把 RAG 当作固定流程，而是在 RAG 上增加一层 agent 控制层，让系统具备“决策 + 工具调用 + 记忆”的能力。

也就是说，V2 的重点不是把检索做得更复杂，而是让 LLM 从“被动生成答案的组件”升级为“负责路径选择与工具调度的决策中枢”。

Agent 的引入，本质上是把系统从“信息检索工具”升级为“任务执行入口”。

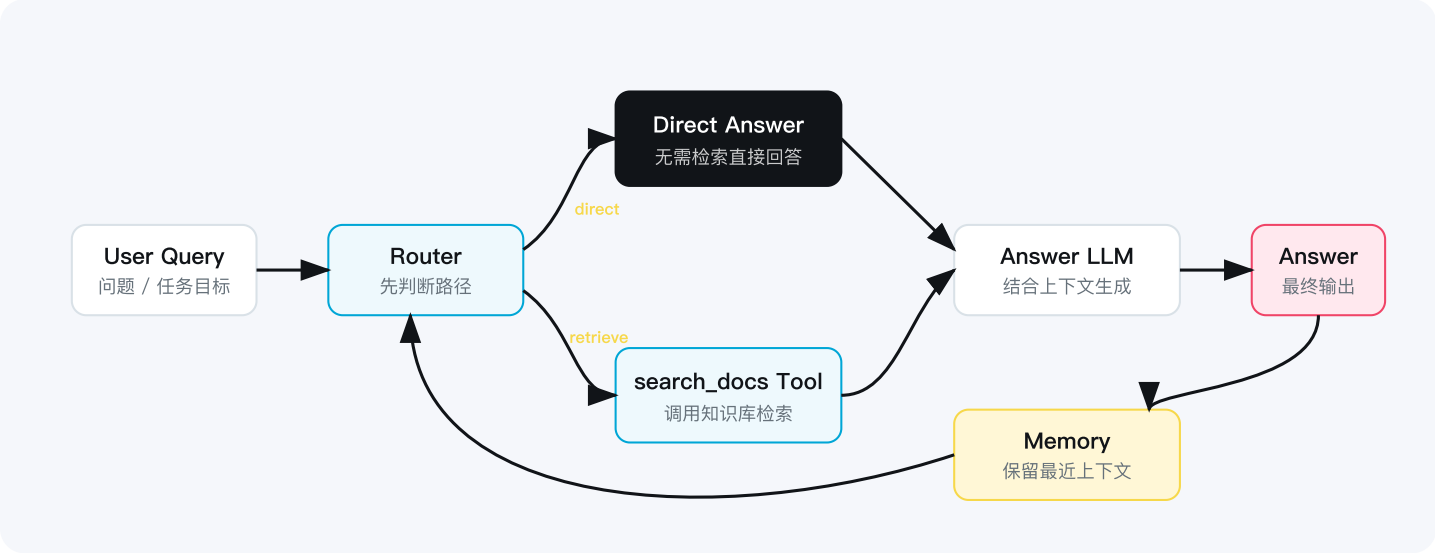

V2 Agentic RAG 决策流程图

4.1 升级动机（承接V1问题）

V1 已经完成“检索增强生成”的基础闭环，但仍存在强制检索、缺少决策、缺少记忆和工具边界不清的问题。因此 V2 的升级目标是：

从产品本质上看，这次升级不是简单地在原有 RAG 上叠加几个模块，而是把系统从“用户提问，系统回答”的问答系统，升级为“用户提出任务目标，系统判断路径并调用工具完成任务”的任务驱动系统。

目标	说明
从固定流程到动态决策	不再每个问题都默认检索，而是先判断是否需要查知识库。
从函数调用到工具调用	将 RAG 检索封装成 search_docs Tool，为后续多工具扩展打基础。
从单轮问答到上下文连续	加入 Memory，保存最近对话，让连续追问更自然。
从黑盒结果到过程可解释	展示 route decision、tool call、tool output 和最终回答。
从检索系统到知识助手	用户输入的不只是问题，也可以是“帮我整理项目”“对比两个项目”这类目标。

4.2 Agent 架构总览

V2 在 V1 的 RAG 能力之上新增 Agent 控制层，包含四个核心模块：

模块	产品职责	技术职责
Router	判断用户问题是否需要检索，识别问题类型。	用 LLM 或规则 prompt 输出结构化 route decision。
Tool	将知识库检索能力封装成标准工具。	search_docs(query) 调用向量检索并返回相关文本。
Memory	保存最近对话，支持上下文继承。	保留最近 3 轮对话或任务摘要。
Agent Core	调度 Router、Tool、Memory 和 Answer 生成。	控制主流程：决策、调用工具、组装上下文、生成答案、更新记忆。

升级后的架构分层：

层级	V1	V2
数据层	文档、chunks、metadata	不变
检索层	query -> vector search	被封装为 search_docs Tool
生成层	基于检索片段回答	根据 Router 决策选择 direct 或 retrieve
控制层	无独立控制层	新增 Agent Core

层级	V1	V2
上下文层	单轮上下文	新增 Memory
体验层	展示搜索和问答结果	展示执行过程、工具调用和下一步建议

4.3 核心模块设计

4.3.1 Router（决策层）

Router 的产品职责是回答一个关键问题：

> 当前用户问题，是否需要查询知识库？

Router 的判断逻辑：

用户问题类型	Route	例子
涉及本地文档、项目资料、历史记录	retrieve	“本地知识助手 Agentic RAG 项目如何介绍？”
需要总结、对比、复盘，但依赖已有资料	retrieve	“对比本地知识助手 和企业知识库 RAG 的区别。”
普通知识解释或轻量闲聊	direct	“什么是 RAG？”
问题过于模糊	retrieve 或追问	“帮我整理一下项目。”

Router 的价值：

- 避免所有问题都强制检索。
- 让系统能区分“普通回答”和“基于知识库回答”。
- 为后续复杂任务分类、Planner 和多工具调度打基础。

4.3.2 Tool（工具调用）

Tool 的核心设计是把 RAG 检索从“内部流程”抽象成“Agent 可调用能力”。
工具定义：

```
search_docs(query) -> related_context
```

产品含义：

设计点	说明
工具名明确	search_docs 表示“查本地知识库”，用户和评审者都容易理解。
输入清晰	输入是自然语言 query 或 Agent 拆解后的子问题。
输出可复核	输出包含片段、来源、标题、路径、source_type。
边界明确	当前 Tool 只读，不自动写入、删除或修改本地文件。

Tool 抽象的关键价值：
一旦 RAG 被封装为 Tool，后续就可以继续扩展其他工具，例如：

- summarize_doc
- compare_projects
- write_to_obsidian
- update_index
- web_search

这会让系统从“一个 RAG 应用”演进为“多工具 Agent 工作台”。
该设计也为未来接入 API、数据库和自动化工具提供统一调用接口。

4.3.3 Memory（记忆层）

Memory 的产品职责是让系统理解最近对话，而不是每次都从零开始。

当前设计：

设计项	说明
保存范围	最近 3 轮对话或最近任务上下文。
保存内容	用户问题、Agent 决策、最终回答摘要。
使用方式	Router 判断和 Answer 生成时都可以参考 Memory。
边界	不把 Memory 当成长期知识库，长期知识仍通过 RAG 索引管理。

为什么 Memory 必须存在：

- 用户会追问“这个结论依据是什么？”。
- 用户会说“继续刚才那个项目”。
- 用户会要求“把上面内容压缩成摘要版本”。

如果没有 Memory，系统无法自然理解“刚才”“这个项目”“上面内容”等指代。

4.3.4 Agent Core（调度/控制）

Agent Core 是 V2 的调度中枢，负责把 Router、Tool、Memory 和 Answer 组合成完整链路。
主流程：

1. 接收用户 query。
2. 读取最近 Memory。
3. Router 判断 action：retrieve 或 direct。
4. 如果 direct，直接调用 LLM 生成回答。
5. 如果 retrieve，调用 search_docs Tool。
6. 将检索结果、用户问题、Memory 组装成 answer prompt。
7. LLM 生成最终回答。
8. 保存本轮对话到 Memory。
9. 返回最终答案、执行步骤和引用来源。

V2 的产品原则：

> Agent 可以调度工具完成任务，但必须在“可控范围内执行”，所有涉及外部写入或状态改变的操作都需要显式确认。

4.4 核心流程（Decision → Tool → Reasoning → Output）

V2 的核心链路从固定的 Retrieve → Generate，升级为 Decision → Tool → Reasoning → Output：

1. 用户输入自然语言问题或任务目标。
2. Agent Core 读取最近 Memory。
3. Router 判断当前问题是否需要检索。
4. 如果不需要检索，进入 direct answer。
5. 如果需要检索，调用 search_docs Tool。
6. Tool 返回相关片段、来源、标题、路径和 source_type。
7. Agent Core 将问题、Memory 和检索结果组装成 answer prompt。
8. LLM 基于上下文进行 reasoning 和 generation。
9. 系统返回答案、引用来源、执行步骤和下一步建议。
10. Memory 保存本轮对话摘要，支持后续追问。

4.5 系统能力升级

V2 的价值不是让系统显得更复杂，而是让用户在真实任务里感受到“更顺手、更可信、更像助手”的体验变化：

价值	说明
更符合用户意图	用户有时需要查资料，有时只是需要解释、改写或总结；Router 让流程更贴合意图。
更可解释	用户能看到系统是否检索、调用了什么工具、基于哪些来源回答。

价值	说明
更可扩展	RAG 工具化后，可以继续接入写作、对比、索引更新等工具。
更适合产品展示	能清楚说明从 RAG 到 Agentic RAG 的演进逻辑，而不是堆功能。
更安全	Agent 默认只读，不自动改文件，避免“能执行但不可控”的风险。

从用户视角看，这次升级最大的变化不是系统更复杂，而是系统更像一个会判断的助手，而不是只会查资料的工具。

5. V1 vs V2 对比

5.1 架构对比

维度	V1：基础 RAG	V2：Agentic RAG
产品定位	本地知识检索与来源问答系统	具备决策、工具调用和上下文能力的本地知识助手
用户输入	一个问题	一个问题或一个任务目标
主流程	query -> retrieve -> answer	query -> route -> tool/direct -> answer -> memory
是否每次检索	默认检索	Router 判断是否需要检索
RAG 角色	固定流程中的检索模块	被封装为 search_docs Tool
控制层	无独立控制层	Agent Core 负责调度
记忆层	无独立记忆层	Memory 保存最近对话

5.2 能力对比

维度	V1：基础 RAG	V2：Agentic RAG
上下文能力	单轮问答为主	保存最近对话，支持连续追问
可解释性	展示来源和答案	展示 route decision、tool call、引用和下一步建议
扩展性	主要扩展检索和 GUI	可扩展多工具、Planner、多 Agent
风险控制	资料本地化、引用复核	增加只读工具边界和人工确认机制

5.3 用户体验对比

维度	V1：基础 RAG	V2：Agentic RAG
提问方式	更像搜索或问答。	可以输入任务目标，例如“帮我整理这个项目的展示材料”。
过程理解	用户看到来源和答案。	用户还能看到决策、工具调用和下一步建议。
连续追问	需要重复背景。	可继承最近上下文，减少重复输入。
信任感	通过引用来源建立信任。	通过执行过程 + 引用来源建立信任。

6. 关键设计思考

6.1 为什么RAG需要决策层

基础 RAG 的默认假设是：用户每次提问都需要检索。

但真实使用中并不是这样：

- 有些问题需要查本地资料。
- 有些问题只需要解释概念。
- 有些问题需要基于上一轮内容继续总结。
- 有些问题应该先追问澄清，而不是直接检索。

Router 的价值是让系统从“固定工作流”变成“动态决策流”。

产品角度看，Router 解决的是意图识别问题；技术角度看，Router 是 Agent 控制层的入口。

6.2 为什么要引入Tool抽象

如果 RAG 只是代码里写死的一段检索逻辑，它只能服务当前问答流程。

但如果把 RAG 封装成 Tool，它就可以被 Agent 调用、组合和扩展。

Tool 抽象的本质是：

> 把能力产品化，把流程模块化。

这一步决定了系统能不能从“单一 RAG 应用”升级为“多工具 Agent 平台”。

6.3 Memory在Agent中的作用

没有 Memory 的系统只会处理孤立问题。

但真实用户的表达往往依赖上下文：

- “这个项目怎么讲？”
- “帮我压缩成摘要。”
- “如果需要对外展示，哪些内容需要脱敏？”
- “那和另一个项目有什么区别？”

Memory 让系统能理解“这个”“刚才”“上面”的指代，也让用户不需要反复输入背景。

产品上，Memory 不是为了炫技，而是为了降低用户重复表达成本。

6.4 RAG vs Agent的本质区别

维度	RAG	Agent
核心能力	检索增强生成	决策、规划、工具调用、记忆
系统角色	回答生成链路中的知识补充层	任务执行链路中的调度中枢
典型问题	“基于资料回答这个问题”	“判断要不要查资料，并决定如何完成任务”
关键模块	retriever、context、prompt	router、tool、memory、planner/core
产品价值	降低幻觉、提供来源	提升任务完成度、过程可解释、能力可扩展

一句话总结：

> RAG 解决“模型不知道我的资料”的问题；Agent 解决“系统如何判断、调用工具并持续完成任务”的问题。

6.5 设计取舍与边界

当前版本没有一开始就把 Planner、多工具自动执行和自动写回全部做进去，不是因为做不到，而是因为这个阶段的产品目标更强调“可控、可解释、可验证”的闭环。

取舍点	当前选择	设计原因
为什么没有引入 Planner	暂不引入独立 Planner，只保留 Router + Agent Core 的轻量编排。	当前任务复杂度还在可控范围内，先验证单工具 Agent 是否真正提升用户价值，避免过早把系统做重。
为什么 Tool 只读	检索工具默认只读，不开放直接写入或执行外部动作。	先保证引用可信和过程透明，避免系统在资料不完整时误操作本地文件。
为什么 Memory 只做短期	只保留最近几轮对话或任务摘要，不把 Memory 设计成长期知识库。	长期知识应该继续由 RAG 索引承载，避免上下文污染和状态失控。
为什么不做自动写入	不自动把结果写回 Obsidian 或更新资料库。	写入类动作一旦出错，成本高于检索错误；当前阶段更适合保留人工确认节点。
当前验证为什么仍是小样本	先用真实个人知识库问题验证核心链路。	当前还没有覆盖复杂长链任务，不能把结果夸大成线上规模化验证。
Router 模糊问题误判风险	保留用户澄清和人工复核节点。	当问题意图不清、上下文不足时，Router 仍可能误判任务类型。
多工具协同暂未做重	暂不引入完整 Planner 和多 Agent 自动执行。	多工具协同需要更严格的任务拆解、状态管理和失败回滚机制。

一句话总结：

> 当前设计优先保证“可控性与可解释性”，再逐步增强自动化能力。

7. 效果评估

7.1 用户体验变化

评估项	V1 表现	V2 改善
提问方式	更像搜索或问答。	可以输入任务目标，例如“帮我整理这个项目的展示材料”。
过程理解	用户看到来源和答案。	用户还能看到决策、工具调用和下一步建议。
连续追问	需要重复背景。	可继承最近上下文，减少重复输入。
信任感	通过引用来源建立信任。	通过执行过程 + 引用来源建立信任。

7.2 系统效率变化

评估项	V1	V2
检索调用	默认检索，可能有冗余。	Router 判断后再检索，减少不必要调用。
任务完成	单轮问答为主。	支持拆解目标、合并来源、生成结构化结果。
扩展成本	新功能容易堆在主流程里。	新能力可以作为 Tool 接入。

7.3 分层评估框架

为了避免只用“回答是否流畅”判断系统效果，本项目把评估拆成三层：

层级	评估重点	典型判断
检索层	Top-K 是否召回正确来源，是否能覆盖同义表达。	用户要找的文件或片段有没有被召回。
生成层	回答是否基于来源，是否清楚标注不确定信息。	有没有脱离材料编造，是否方便用户回原文复核。
Agent 层	Router 是否能判断任务类型，并选择检索、问答、索引说明或澄清。	该直接回答时不多检索，该查资料时能调用 Tool，该补充条件时会提醒用户。

7.4 小样本验证结果

当前验证不是大规模线上 A/B，而是围绕个人知识库真实任务构造的小样本验证。已整理 10 条代表性测试问题，覆盖协作规则、GUI 使用、索引维护、换电脑迁移、项目介绍、公开封装和跨项目召回。

说明：测试问题来自真实个人知识库使用场景，而非人工构造的标准问答集。

指标	当前结果	说明
代表性测试问题	10 条	来自真实个人知识库使用场景，不是随机构造问题。
来源召回结果	9 条命中，1 条基本命中	“基本命中”指能召回相关来源，但仍需要用户进一步筛选。
回答可用性	约 8/10	人工判断回答是否基于来源、是否能辅助复盘。
Agent 任务判断	可区分检索、来源问答、索引维护和澄清类任务	当前是 MVP 级验证，复杂任务仍需要继续扩充问题集。

这组结果的意义不是证明系统已经成熟，而是说明我有意识地把 AI 产品从“能跑 demo”推进到“有问题集、有判断标准、有迭代方向”。

当前验证情况：

- 已完成 163 个文件、390 个 chunks 的本地索引验证。
- 已完成 FastAPI GUI 的搜索、问答、索引状态和 Agent 助手入口。
- Agent 能输出任务类型、执行步骤、引用来源和下一步建议。
- 当前版本默认只读，涉及写文件或重建索引时需要人工确认。

7.5 关键效果总结

一句话用户价值：

> 用户不再需要记住“文件在哪”，只需要表达“我想要什么”，系统就能找到依据并给出可验证答案。

- 用户价值维度：
  - 信息获取方式从“依赖目录和关键词查找”变为“按语义和任务目标获取信息”。
  - 回答可信度从“模型说了什么”提升为“模型说了什么，以及依据来自哪里”。
  - 多轮体验从“每轮都要重新交代背景”变为“系统能继承最近上下文继续完成任务”。
  - 用户对系统的理解从“黑盒问答”变为“可看到决策路径、工具调用和引用依据的透明过程”。
- 系统能力维度：
  - 检索效率从“默认每次都检索”升级为“先判断是否检索，再调用工具”，减少无效调用。
  - 系统定位从“静态检索问答”升级为“动态决策与任务执行入口”。
  - 架构能力从“单一 RAG 流程”升级为“可扩展的 Router + Tool + Memory + Agent Core 编排结构”。
  - 扩展方式从“继续堆功能”升级为“通过统一工具接口接入更多能力”，为后续多工具 Agent 留出空间。

7.6 与传统方式对比

维度	传统方式	本地知识助手 Agentic RAG
找资料	关键词搜索、按目录翻文件。	自然语言语义检索，能覆盖同义表达和跨文件线索。
找答案	用户打开多个文件后手动拼结论。	系统先召回来源，再组织可复核答案。
可信度	依赖用户记忆和人工判断。	回答绑定来源片段，可回到原文确认。
连续任务	每次都重新搜索、重新交代背景。	Memory 保留最近上下文，Router 判断是否需要继续检索。

本质提升是：从“找文件”升级为“找答案 + 找依据”。

8. 未来扩展

8.1 多工具Agent

后续可以在 search_docs 之外增加更多工具：

工具	作用
summarize_doc	对指定文档生成摘要。
compare_projects	对两个项目做差异对比。
update_index	检查并触发小批量索引更新。
write_to_obsidian	将高价值结果保存为 Obsidian 笔记，但必须写入前确认。
export_brief	将回答整理成作品集文档、项目简报或复盘材料。

8.2 Planner（任务拆解）

当用户输入的是复杂目标时，例如“帮我整理某个项目方案”，系统不应该只做一次检索，而应该先拆任务：

1. 明确目标和资料范围。
2. 检索相关项目资料。
3. 提炼产品逻辑与关键证据。
4. 生成结构化内容草稿。
5. 检查引用来源和风险表达。

Planner 的价值是把复杂目标拆成可执行步骤，再交给 Agent Core 调度工具。

8.3 多Agent协作

进一步可以扩展为多 Agent 协作：

Agent	职责
Research Agent	负责检索资料和整理证据。
Product Agent	负责提炼产品逻辑、用户价值和功能边界。

Agent	职责
Content Agent	负责把项目内容整理成结构化表达。
Review Agent	负责检查是否夸大、是否缺少依据、是否有风险表达。

多 Agent 的价值不是增加复杂度，而是让不同任务角色分工更清晰，适合复杂项目复盘、作品集生成和长期知识管理。

8.4 产品化与延展路径

这部分只作为产品化思考，不作为当前项目已经商业化的证明。更合理的表达是：个人知识工作台 MVP 已经验证了本地检索、来源问答、Agent 任务判断和 GUI 使用闭环，后续可以探索小团队私有知识助手。

延展方向	设计设想	前提条件
小团队本地知识库	支持 3-10 人团队按项目空间管理资料。	需要补充成员权限、资料更新规则和共享索引策略。
私有部署模板	提供本地或内网部署说明，适合不愿上传资料的团队。	需要把安装、索引、备份和故障处理标准化。
评估与运营面板	展示索引覆盖率、常见问题、命中率和低质量回答。	需要沉淀稳定的问题集和人工标注规则。
垂直场景方案	面向咨询、产品、运营、设计等知识密集团队做轻量方案。	需要先验证团队资料更新频率、复核成本和协作流程。

商业化路径可以设想为一次性私有部署模板、轻量订阅版或垂直团队知识库方案，但当前阶段不宜把重点放在营收模型上。更可信的讲法是：先证明个人场景可用，再说明它具备向小团队场景延展的产品基础。

9. 我的角色（AI PM）

我在这个项目中的角色不是单纯实现一个技术 demo，而是从 AI 产品经理视角完成了从问题定义到可演示产品的闭环。

工作内容	我的职责
9.1 产品设计	定义目标用户、使用场景、核心痛点、MVP 范围、成功指标和风险边界。
9.2 架构设计	将系统拆成数据源、文档处理、向量库、检索、生成、GUI 和 Agent 控制层。
9.3 Prompt设计	设计 Router prompt 和 Answer prompt，让系统能判断是否检索，并基于来源回答。
9.4 Demo验证	完成本地索引、GUI 检索、来源问答、Agent 助手入口和 smoke test。
风险控制	坚持本地优先、来源可追溯、Agent 只读、写入前人工确认。
作品集封装	将项目从“技术实现”转化为“产品演进案例”，用于展示 AI PM 对 RAG 和 Agent 的理解。
产品化思考	评估从个人工具 MVP 延展到小团队私有知识助手的条件、边界和风险。

这个项目体现的 AI PM 能力：

- 能从真实场景定义问题，而不是为了技术而技术。
- 能把 RAG、Tool Calling、Memory 等技术概念转成产品模块。
- 能说明每个设计选择背后的用户价值和边界。
- 能用 V1 到 V2 的演进讲清楚产品迭代逻辑。
- 能区分“当前已验证能力”和“后续产品化设想”，避免把 MVP 夸大成成熟商业产品。

本项目本质上也训练了我三类更底层的能力：

- 将技术能力（RAG / Tool / Memory）抽象为产品模块的能力。
- 从用户问题出发设计系统演进路径的能力。
- 在“能力增强”与“系统可控性”之间做取舍的能力。